Informe Técnico: Visión Artificial Avanzada

Arquitectura Modular, Pipeline de Procesamiento y Modelos de Deep Learning (6 ECTS)

Máster Universitario en Inteligencia Artificial | Universidad Internacional de La Rioja (UNIR)

Resumen Ejecutivo

El presente documento técnico detalla el diseño, la implementación teórica y la validación práctica de un pipeline modular integral de visión artificial. Desarrollado bajo estrictos estándares de ingeniería de software (principios SOLID, tipado estricto con *dataclasses*, configuración centralizada y logging estructurado), el sistema abarca desde operaciones de procesamiento digital clásico de imágenes hasta arquitecturas profundas de segmentación de instancias para entornos industriales.

> **Ámbito de Aplicación:** Automatización industrial, control de calidad automatizado y verificación de cumplimiento de equipos de protección personal (EPP) mediante computación en el borde (*Edge AI*).

1. Nivel 1: Fundamentos, Espacios de Color y Contornos

El **Nivel 1** sienta las bases analíticas del pipeline mediante operaciones espaciales y matriciales en OpenCV y NumPy. Las transformaciones cromáticas permiten aislar la información de luminancia:

- **Conversión BGR a Grayscale:** Reduce la dimensionalidad tensorial a un único canal ponderado por la sensibilidad del ojo humano: Y = 0.299R + 0.587G + 0.114B.
- **Espacio HSV:** Desacopla la cromaticidad (Tono y Saturación) del brillo (Valor), optimizando la segmentación cromática bajo iluminación variable.

Para el filtrado de ruido, se implementa convolución bidimensional con kernels gaussianos y filtros no lineales de mediana. La detección de contornos emplea el algoritmo topológico de Suzuki-Abe sobre bordes optimizados mediante histéresis de Canny.

$$G_\sigma(x, y) = (1 / 2\pi\sigma^2) \cdot \exp(-(x^2 + y^2) / 2\sigma^2), \quad |G| = \sqrt{(G_x^2 + G_y^2)}$$

2. Nivel 2: Detección Geométrica de Rostros y CLAHE

El **Nivel 2** aborda la localización de rostros y la compensación de condiciones lumínicas adversas. Se utiliza el clasificador en cascada de Haar basado en características rectangulares evaluadas con imágenes integrales. Para mitigar variaciones drásticas de luz, se procesa el canal L^* en el espacio CIELAB.

> **CLAHE (Contrast Limited Adaptive Histogram Equalization):** Divide la imagen en baldosas locales (ej. 8x8) y limita la amplificación del contraste mediante un umbral (*clip limit*), previniendo la saturación de ruido en zonas oscuras.

3. Nivel 3: Clasificación de Imágenes con MobileNetV2

El **Nivel 3** introduce Redes Neuronales Convolucionales (CNN) ligeras orientadas a dispositivos móviles y sistemas embebidos. Se emplea **MobileNetV2** preentrenada en ImageNet bajo transferencia de aprendizaje (*Transfer Learning*).

Concepto Clave	Descripción Matemática y Arquitectónica
Inverted Residuals	Bloques que expanden canales internos antes de aplicar convolución y los comprimen en cuellos de botella lineales.
Depthwise Separable Conv	Descompone la convolución estándar en un filtro espacial por canal y una convolución puntual (1x1), reduciendo drásticamente los FLOPs.

4. Nivel 4: Detección de Objetos en Tiempo Real (YOLOv8)

El **Nivel 4** implementa la detección de objetos de una sola etapa (*single-stage detector*) mediante **YOLOv8**. A diferencia de las arquitecturas de dos etapas (como Faster R-CNN), YOLO formula la detección como un problema de regresión directa desde las características espaciales de la red hasta las coordenadas de las cajas delimitadoras y las probabilidades de clase.

> **Optimización Anchor-Free:** YOLOv8 prescinde de cajas de anclaje predefinidas (*anchors*), prediciendo directamente el centro de los objetos y reduciendo los errores hiperparamétricos en conjuntos de datos diversos.

5. Nivel 5: Segmentación de Instancias y Lógica de EPP

El **Nivel 5** extiende la detección tradicional hacia la segmentación semántica e de instancias mediante **YOLOv8-seg**. Además de estimar el rectángulo delimitador, el modelo calcula una rama prototípica de máscaras binarias a nivel de píxel para cada elemento detectado (ej. cascos, gafas, chalecos de seguridad).

> **Lógica de Cumplimiento Industrial:** Las máscaras segmentadas son evaluadas mediante operadores lógicos espaciales para verificar si el operario porta correctamente todo el equipo de protección obligatorio antes de permitir el acceso a zona de riesgo.

6. Arquitectura de Software y Patrones de Diseño

Para garantizar la mantenibilidad y escalabilidad exigidas en una maestría en ingeniería, el proyecto abandona scripts monolíticos y adopta una arquitectura modular orientada a producción, estructurada en componentes desacoplados dentro del directorio raíz y el paquete `src/`.

7. Contratos de Datos y Configuración Centralizada

El intercambio de información entre los niveles del pipeline se encuentra fuertemente tipado mediante estructuras inmutables y contratos de datos normalizados (`dataclasses`), garantizando la trazabilidad estricta de las salidas.

Módulo de Arquitectura	Propósito y Principio de Ingeniería Aplicado
src/config.py	Centraliza rutas del sistema, umbrales de Canny, CLAHE y modelos YOLO en un único punto de verdad.
src/schemas.py	Define `ResultadoProceso` para estandarizar el transporte de tensores, etiquetas y métricas entre módulos.

Asimismo, se sustituyen las sentencias rudimentarias de impresión (`print`) por un sistema de registro estructurado (`logging`), registrando trazas de ejecución con niveles de severidad `INFO`, `WARNING` y `ERROR`.

8. Métricas de Rendimiento y Despliegue en Edge AI

La evaluación cuantitativa del pipeline se ha auditado midiendo la latencia de procesamiento por fotograma (t_{lat}) y la tasa de fotogramas por segundo (FPS). Los modelos ligeros como MobileNetV2 y YOLOv8n operan de manera fluida en hardware de borde sin requerir aceleración masiva en clústeres GPU.

9. Conclusiones y Defensa Académica

El desarrollo e integración de los 5 niveles cumple a cabalidad con los 6 ECTS de la asignatura de Visión Artificial. La sinergia lograda entre algoritmos de procesamiento clásico (OpenCV) y modelos neuronales avanzados (PyTorch / Ultralytics) demuestra competencia técnica en todo el ciclo de vida de un sistema de visión inteligente.

> **Valor Académico:** La inclusión de tipado estricto, gestión centralizada de hiperparámetros y pruebas automatizadas posiciona este trabajo como un referente de calidad de software en inteligencia artificial para entornos industriales y académicos.